

CASO DE USO - TFM

Sistema de Monitorización Regulatorio Inteligente con IA

Data Engineering + Inteligencia Artificial + IA Generativa



Trabajo Fin de Máster



2025

Contenidos

Estructura de la presentación

- | | | | |
|----|---|----|---|
| 01 | Contexto del Problema
Desafíos actuales en entornos regulados | 02 | El Problema a Resolver
Objetivo del sistema inteligente |
| 03 | Descripción del Caso de Uso
Prototipo funcional propuesto | 04 | Funcionalidades del Prototipo
Capacidades del sistema |
| 05 | Fuera de Alcance
Límites del proyecto | 06 | Arquitectura Tecnológica
Stack Microsoft/Azure |
| 07 | Técnicas de IA Aplicadas
Data Engineering, NLP, IA Generativa | 08 | Evaluación y Resultados
Criterios de éxito y valor esperado |

Contexto del Problema

Desafíos en entornos empresariales regulados

Sectores Afectados

 Finanzas

 Tecnología

 Energía

 Salud

Proceso Manual Actual

- 1 Revisar manualmente boletines oficiales y portales regulatorios
- 2 Leer documentos legales extensos (PDFs, directivas, reglamentos)
- 3 Determinar relevancia de regulaciones para la organización
- 4 Analizar posibles impactos operativos o técnicos

Impacto del Proceso Manual

Tiempo promedio de revisión **40-60h**

Por documento regulatorio complejo

Documentos anuales (UE) **3,500+**

Nuevas regulaciones y directivas

Tasa de error humano **15-25%**

En identificación de requisitos relevantes

Conclusión

Este proceso es **lento, costoso y propenso a errores**. Las empresas necesitan soluciones que automaticen y mejoren la eficiencia del análisis regulatorio sin comprometer la precisión.

El Problema a Resolver

¿Cómo aplicar IA moderna al análisis regulatorio?



Pregunta Central

¿Cómo podemos utilizar técnicas modernas de **Data Engineering + Inteligencia Artificial + IA Generativa** para asistir en el análisis de documentación regulatoria?



Objetivo del Sistema

NO reemplazar a expertos legales, sino construir un **sistema inteligente de apoyo** que potencie sus capacidades.

- ✓ Asistencia, no sustitución
- ✓ Aumento de productividad
- ✓ Reducción de tiempo de análisis
- ✓ Mejora en cobertura de documentos



Capacidades del Sistema



Organizar información regulatoria

Estructurar y catalogar documentos de forma inteligente



Buscar contenido semánticamente

Más allá de keywords: búsqueda por concepto



Detectar información relevante

Clasificación automática por relevancia



Generar resúmenes y explicaciones

IA Generativa para síntesis de contenido

Descripción del Caso de Uso

Prototipo funcional de sistema inteligente



Propuesta del Proyecto

Diseñar un **prototipo funcional** de un sistema capaz de trabajar con documentos regulatorios públicos y demostrar cómo la IA puede facilitar su análisis.



Flujo de Trabajo del Sistema



Ingesta de Documentos

PDFs regulatorios públicos (regulación europea)



Procesamiento y Estructuración

Extracción de texto y organización del contenido



Análisis con IA

Embeddings, búsqueda semántica, clasificación



Generación de Insights

Resúmenes, explicaciones y recomendaciones



Alcance de Datos



Conjunto Acotado

Documentos normativos públicos de la UE



Formatos

PDFs, documentos de texto, directivas



Ejemplos

GDPR, DORA, AI Act, NIS2



Enfoque

El sistema operará sobre un **conjunto representativo** de documentos para demostrar la viabilidad técnica y el valor del enfoque propuesto.

Funcionalidades del Prototipo

Capacidades del sistema inteligente



Ingesta de Documentos



Soporte PDF

Procesamiento de documentos regulatorios en formato PDF



Texto Plano

Ingesta de archivos de texto y documentos estructurados



Carga Masiva

Procesamiento batch de múltiples documentos



Procesamiento de Contenido



Extracción de Texto

OCR y extracción de contenido textual con Azure AI Document Intelligence



Estructuración

Organización jerárquica de secciones, artículos y párrafos



Metadatos

Enriquecimiento con fecha, tipo, jurisdicción, área temática



Representaciones Semánticas



Embeddings

Generación de vectores semánticos con Azure OpenAI



Vector Store

Almacenamiento en base de datos vectorial (Azure AI Search)



Chunking

División inteligente en fragmentos semánticamente coherentes



Búsqueda Semántica



Búsqueda por Concepto

Más allá de keywords: entiende el significado



Similaridad

Cálculo de similitud semántica entre consultas y documentos



Filtros

Filtrado por fecha, tipo, jurisdicción, área



Clasificación de Relevancia



Scoring

Asignación de puntuación de relevancia por documento



Categorización

Clasificación por área de impacto: legal, técnico, operativo



Alertas

Notificación de documentos de alta prioridad



Generación de Resúmenes



Resúmenes

Síntesis automática de documentos extensos



Explicaciones

Clarificación de términos técnicos y legales complejos



RAG

Respuestas fundamentadas en documentos reales

Fuera de Alcance

Límites claros del proyecto



Muy Importante

El proyecto **NO requiere** los siguientes elementos. Estos límites definen el alcance tecnológico y experimental del prototipo.



Validación Jurídica Formal

El sistema no proporciona validación legal vinculante. Las salidas son orientativas y requieren revisión por profesionales legales cualificados.



Automatización Legal Vinculante

No se trata de un sistema que tome decisiones legales automáticas. Es una herramienta de asistencia, no de automatización completa.



Sistemas de Compliance Reales

No es un sistema corporativo de compliance listo para producción. Es un prototipo experimental para demostración de concepto.



Integraciones Empresariales Complejas

No incluye integraciones complejas con ERP, CRM u otros sistemas empresariales existentes. El foco es el core del sistema.



Cobertura Multi-País Masiva

El prototipo se centra en un conjunto acotado de regulaciones (ej. europeas). No cubre todas las jurisdicciones globalmente.



El Foco es Tecnológico y Experimental

Este proyecto es un **experimento tecnológico** para demostrar la aplicabilidad de técnicas modernas de IA al análisis regulatorio, no un producto legal o de compliance empresarial.

Arquitectura Tecnológica

Stack Microsoft / Azure

Arquitectura del Sistema



Ingesta

Azure Blob Storage

Azure Data Lake

Azure Functions



Procesamiento

Azure AI Document Intelligence

Azure Functions

Azure Logic Apps



Embeddings

Azure OpenAI

text-embedding-3

Vectorización



Búsqueda

Azure AI Search

Índice Vectorial

RAG



Generación

Azure OpenAI GPT

Resúmenes

Explicaciones



Almacenamiento de Datos



Azure Blob Storage

Almacenamiento de documentos originales (PDFs)



Azure Data Lake

Almacenamiento de datos procesados y estructurados



Azure SQL / Cosmos DB

Metadatos y resultados de análisis



Servicios de IA



Azure AI Document Intelligence

OCR y extracción de texto de documentos



Azure OpenAI

Embeddings y modelos generativos (GPT-4)



Azure AI Search

Búsqueda semántica y vectorial

Técnicas de IA: Data Engineering

Procesamiento y organización de datos

ml4devs.com/big-data-pipeline



Data Engineering en el Sistema

El **Data Engineering** proporciona la base para el procesamiento eficiente de documentos regulatorios no estructurados, estableciendo pipelines robustos de ingestión y transformación.



Procesamiento de Datos No Estructurados

Extracción de Texto (OCR)

Azure AI Document Intelligence extrae texto de PDFs escaneados y documentos con layouts complejos, incluyendo tablas y estructuras jerárquicas.

Estructuración de Contenido

Identificación automática de secciones, artículos, subsecciones y jerarquías documentales para organizar el contenido de forma navegable.

Extracción de Tablas

Conversión de tablas regulatorias en datos estructurados (CSV, JSON) preservando relaciones y formato.



Pipelines de Ingestión

Ingesta Automatizada

Azure Functions y Logic Apps orquestan la ingesta de documentos desde múltiples fuentes (portales regulatorios, APIs, carga manual).

Transformación y Limpieza

Procesos ETL que normalizan formatos, eliminan ruido, estandarizan codificación y preparan datos para análisis posterior.

Procesamiento Batch y Streaming

Soporte para procesamiento masivo de archivos históricos y procesamiento en tiempo real de nuevas publicaciones.



Organización Documental

Enriquecimiento de Metadatos

Extracción automática de fecha de publicación, número de referencia, autoridad emisora, área temática, jurisdicción.

Taxonomías y Categorización

Clasificación en categorías jerárquicas: tipo de regulación, sector afectado, nivel de obligatoriedad, fecha de entrada en vigor.

Relaciones entre Documentos

Identificación de referencias cruzadas, enmiendas, derogaciones y dependencias entre regulaciones.

Técnicas de IA: NLP Tradicional

Procesamiento de Lenguaje Natural clásico



NLP para Análisis Regulatorio

Las técnicas de **NLP tradicional** permiten comprender el contenido semántico de documentos legales, superando las limitaciones de la búsqueda por palabras clave.



Similaridad Semántica

Embeddings de Texto

Azure OpenAI genera vectores densos de alta dimensionalidad (1536 dimensiones) que capturan el significado semántico de textos regulatorios.

Cálculo de Similitud

Uso de métricas como similitud coseno para medir la cercanía semántica entre consultas y fragmentos de documentos.

Búsqueda por Concepto

Permite encontrar documentos relacionados con "protección de datos personales" incluso si no contienen esas palabras exactas.



Clasificación de Relevancia

★ Scoring de Relevancia

Algoritmos que asignan puntuaciones de relevancia basadas en similitud semántica, metadatos y contexto organizacional.

📁 Categorización Multi-Label

Clasificación de documentos en múltiples categorías simultáneas: área legal, impacto técnico, obligatoriedad, prioridad.

🔔 Detección de Prioridad

Identificación automática de documentos que requieren atención inmediata basada en fecha de cumplimiento y criticidad.



Representaciones Vectoriales

✂️ Chunking Inteligente

División de documentos extensos en fragmentos semánticamente coherentes (chunks) de 500-1000 tokens con solapamiento.

🗄️ Vector Stores

Almacenamiento eficiente de embeddings en Azure AI Search con índices optimizados para búsqueda de similitud de alta velocidad.

⚡ Indexación Híbrida

Combinación de búsqueda vectorial semántica con búsqueda textual tradicional (BM25) para resultados óptimos.

Técnicas de IA: IA Generativa

Generación de contenido con modelos LLM



IA Generativa para Documentos Regulatorios

La **IA Generativa** (Azure OpenAI GPT-4) permite crear resúmenes, explicaciones y respuestas contextuales basadas en el contenido real de documentos regulatorios mediante RAG.



Generación de Resúmenes

Resúmenes Ejecutivos

Síntesis automática de documentos extensos (50+ páginas) en resúmenes concisos de 1-2 páginas destacando puntos clave.

Extracción de Requisitos

Identificación y listado automático de obligaciones, plazos de cumplimiento y acciones requeridas por la regulación.

Simplificación de Lenguaje

Traducción de texto legal complejo a lenguaje accesible para stakeholders no técnicos manteniendo precisión legal.



Explicación de Contenido

Respuestas a Preguntas

Sistema de Q&A que responde preguntas específicas sobre el contenido regulatorio en lenguaje natural.

Definición de Términos

Explicación de términos técnicos y legales complejos con ejemplos contextualizados al sector de la organización.

Análisis de Impacto

Generación de análisis preliminar de impacto en operaciones, tecnología y cumplimiento basado en el contenido.



RAG: Retrieval-Augmented Generation

Recuperación Contextual

Búsqueda semántica de fragmentos relevantes del documento antes de generar respuestas, asegurando fundamentación.

Citas y Referencias

Las respuestas incluyen referencias a secciones específicas del documento fuente para verificación por expertos.

Reducción de Alucinaciones

RAG minimiza respuestas inventadas al limitar la generación al contexto recuperado de documentos reales.



Ventaja de RAG vs LLM Puro

RAG combina la **potencia generativa** de los LLMs con la **precisión documental** de la recuperación de información, proporcionando respuestas contextualizadas, verificables y actualizadas sin necesidad de reentrenar el modelo.

Evaluación y Resultados Esperados

Criterios de éxito y valor del proyecto



Criterios de Evaluación



Calidad de Recuperación

Precisión y recall en búsqueda semántica. Métricas: MRR, NDCG@k, precisión@k.



Comparación Búsquedas

Benchmark: búsqueda clásica (BM25) vs semántica. Mejora esperada: 30-50% en relevancia.



Consistencia de Clasificación

Evaluación de estabilidad en clasificación de relevancia. Coeficiente Kappa de Cohen.



Análisis de Limitaciones

Identificación de casos de fallo: alucinaciones, ambigüedad, contexto insuficiente.



Valor del Proyecto



Diseño del Sistema

Arquitectura bien fundamentada que integra múltiples componentes de IA de forma coherente.



Aplicación Correcta de IA

Uso apropiado de técnicas de Data Engineering, NLP e IA Generativa según su propósito.



Justificación Técnica

Razonamiento sólido en la selección de tecnologías, arquitectura y técnicas aplicadas.



Análisis Crítico

Evaluación honesta de fortalezas, debilidades, limitaciones y áreas de mejora.



Clave del Proyecto

No se evalúa construir un **producto empresarial completo**. Se evalúa:



Pensamiento de ingeniería



Uso correcto de IA y datos



Justificación técnica



Análisis de resultados